


Правительство Российской Федерации
Федеральное государственное автономное
образовательное учреждение высшего образования
«Национальный исследовательский университет «Высшая школа экономики»
Факультет компьютерных наук
Образовательная программа бакалавриата 09.03.04 «Программная инженерия»

ОТЧЕТ
по учебной (технологической) практике
в Департаменте больших данных и информационного поиска
факультета компьютерных наук НИУ ВШЭ

Выполнила студентка

группы БПИ247

В.А. Путинцева


(подпись)

Проверил:

Руководитель практики от факультета компьютерных наук

Гринберг Петр Маркович

Приглашенный преподаватель, Департамент больших данных и информационного поиска,
ФКН НИУ ВШЭ

Дата 01.08.2026

(оценка)

(подпись)

Москва - 2026

АННОТАЦИЯ

Учебная практика проходила на факультете компьютерных наук Национального исследовательского университета «Высшая школа экономики» в рамках мини-курса по глубокому обучению с 1 по 14 июля 2026 года. Руководителем практики являлся Гринберг Петр Маркович.

В ходе практики были рассмотрены основные принципы обучения нейронных сетей, полносвязные и сверточные архитектуры, модели для последовательных данных, трансформеры и большие языковые модели. Отдельные занятия были посвящены обработке аудио, мультимодальным моделям и методам объяснения решений нейронных сетей.

Практическим итогом мини-курса стало выполнение домашнего задания по обнаружению синтезированной и преобразованной речи. Для решения задачи была реализована модель LFCC-LCNN на PyTorch, проведено обучение на наборе данных ASVspoof 2019 и выполнена оценка качества по метрике EER.

СОДЕРЖАНИЕ

АННОТАЦИЯ.....	1
1. ЦЕЛЬ И ЗАДАЧИ ПРАКТИКИ	3
1.1. Цель.....	3
1.2. Задачи.....	3
2. ОПИСАНИЕ МЕСТА ПРОХОЖДЕНИЯ ПРАКТИКИ	4
3. ОБЗОР ИЗУЧЕННЫХ МАТЕРИАЛОВ, ТЕХНОЛОГИЙ И МЕТОДОВ	5
3.1. Основы глубокого обучения	5
3.2. Архитектуры нейронных сетей.....	6
3.3. Современные направления глубокого обучения	7
4. МЕТОДЫ, ТЕХНОЛОГИИ И СРЕДСТВА РАЗРАБОТКИ.....	8
4.1. Используемые инструменты	8
4.2. Методы решения практической задачи.....	9
5. ОПИСАНИЕ ВЫПОЛНЕННЫХ РАБОТ И ПОЛУЧЕННЫХ РЕЗУЛЬТАТОВ	11
5.1. Ход выполнения практической работы.....	11
5.2. Результаты экспериментов.....	12
6. ЗАКЛЮЧЕНИЕ	14
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	15
ПРИЛОЖЕНИЕ	17

1. ЦЕЛЬ И ЗАДАЧИ ПРАКТИКИ

1.1. Цель

Целью прохождения практики являлось изучение основ глубокого обучения и освоение написания кода для обучения и применения нейронных сетей. Практика была направлена на сочетание лекционного материала с самостоятельной реализацией моделей и выполнением итогового домашнего задания.

1.2. Задачи

1. Изучить основные концепции глубокого обучения.
2. Научиться обучать и использовать нейронные сети в коде.
3. Рассмотреть основные архитектуры нейронных сетей и области их применения.
4. Освоить базовые инструменты организации и контроля экспериментов.
5. Применить полученные знания на практике путем решения домашнего задания по обработке аудио.
6. Подготовить отчет о выполненной работе и полученных результатах.

2. ОПИСАНИЕ МЕСТА ПРОХОЖДЕНИЯ ПРАКТИКИ

Практика проходила на факультете компьютерных наук НИУ ВШЭ в формате учебного мини-курса по глубокому обучению. Руководителем практики являлся Гринберг Петр Маркович, приглашенный преподаватель Департамента больших данных и информационного поиска факультета компьютерных наук НИУ ВШЭ.

Факультет компьютерных наук осуществляет подготовку специалистов в области программной инженерии, анализа данных, машинного обучения и искусственного интеллекта. Учебный процесс сочетает теоретические дисциплины с проектной и практической работой, в том числе с использованием современных библиотек и вычислительных средств для разработки моделей.

Мини-курс состоял из восьми лекций и домашнего заданий. На занятиях рассматривались как базовые принципы глубокого обучения, так и более современные направления. Практические материалы были организованы в виде семинарских ноутбуков и примеров кода. Помимо этого, курс включал одно домашнее задание, в котором необходимо было самостоятельно построить и обучить модель для обнаружения поддельной речи.

3. ОБЗОР ИЗУЧЕННЫХ МАТЕРИАЛОВ, ТЕХНОЛОГИЙ И МЕТОДОВ

3.1. Основы глубокого обучения

В начале мини-курса были рассмотрены основные понятия глубокого обучения и общий процесс построения модели. Практическая часть включала работу с тензорами, автоматическим вычислением градиентов и основными объектами PyTorch. Особое внимание уделялось правильному разделению данных на обучающую, валидационную и оценочную части, а также назначению каждой из них.

Были изучены этапы обучения нейронной сети: подготовка данных, прямой проход, вычисление функции потерь, обратное распространение ошибки и обновление параметров оптимизатором. Рассматривалось влияние скорости обучения, размера пакета, количества эпох и регуляризации на качество и устойчивость модели.

На семинарах основные операции выполнялись непосредственно в коде. Были освоены классы Dataset и DataLoader, создание собственных модулей на основе nn.Module, работа с устройствами CPU и GPU, а также организация циклов обучения и проверки качества. Эти навыки использовались далее при выполнении итогового задания.

Также обсуждались типичные ошибки при проведении экспериментов: переобучение, использование оценочных данных для настройки модели, некорректное усреднение метрик и отсутствие проверки отдельных частей программного конвейера перед длительным обучением.

3.2. Архитектуры нейронных сетей

В рамках мини-курса были изучены полносвязные и сверточные нейронные сети. На примере задач классификации рассматривались структура слоя, функции активации, формирование выхода модели и обучение с помощью градиентных методов. Для сверточных сетей основное внимание уделялось выделению локальных признаков, изменению размеров тензоров и последовательному построению более сложных представлений.

Отдельный блок был посвящен моделям для последовательных данных. Были рассмотрены рекуррентные сети, LSTM и GRU, способы обработки последовательностей различной длины и особенности обучения моделей, в которых результат зависит от предыдущих элементов.

Затем были изучены трансформеры и механизм внимания. В практических материалах рассматривалась обработка текстовых последовательностей, использование масок и формирование представлений токенов. Эти темы стали основой для знакомства с современными языковыми моделями.

На занятиях по большим языковым моделям обсуждались общие принципы их предварительного обучения и применения, возможности адаптации модели под конкретную задачу и ограничения, связанные с вычислительной стоимостью и качеством данных. Материал был направлен на понимание места LLM среди других архитектур глубокого обучения.

3.3.Современные направления глубокого обучения

Одно из занятий было посвящено обработке аудио. Рассматривались способы представления звукового сигнала, переход от временной формы к частотно-временному представлению и применение нейронных сетей к задачам распознавания речи, ключевых слов и обнаружения поддельного аудио.

В блоке по мультимодальным моделям изучались подходы к совместной обработке информации разных типов. Обсуждались способы объединения текстовых, звуковых и визуальных признаков, а также использование общих представлений для решения задач, в которых одной модальности недостаточно.

Дополнительно были рассмотрены автоэнкодеры и современные генеративные модели. Основное внимание уделялось общему принципу обучения скрытого представления данных и возможностям использования таких моделей для восстановления, генерации и преобразования информации.

Заключительная тема мини-курса была связана с объяснимым искусственным интеллектом. Были рассмотрены подходы, позволяющие анализировать вклад входных признаков и отдельных частей данных в решение модели. Практические примеры показали, что оценка качества модели должна дополняться анализом причин, по которым получено то или иное предсказание.

4. МЕТОДЫ, ТЕХНОЛОГИИ И СРЕДСТВА РАЗРАБОТКИ

4.1. Используемые инструменты

Основным языком программирования в ходе практики являлся Python. Для разработки и обучения нейронных сетей использовалась библиотека PyTorch, предоставляющая средства для работы с тензорами, автоматическим дифференцированием, моделями и оптимизаторами. Обработка аудиоданных выполнялась с использованием функций PyTorch и torchaudio.

Работы на семинаре и самостоятельное задание выполнялись в Jupyter Notebook. Такой формат позволял последовательно проверять чтение данных, преобразования и работу моделей. Домашнее задание было оформлено как модульный проект на PyTorch.

Обучение проводилось в среде Kaggle с использованием графического ускорителя. Для хранения истории экспериментов и сравнения запусков применялся сервис Weights & Biases. В нем фиксировались значения функции потерь, метрики качества и параметры запуска.

Для работы с результатами также использовались NumPy и Matplotlib. Система контроля версий Git применялась для последовательного сохранения изменений и организации разработки проекта.

4.2. Методы решения практической задачи

Практическая задача заключалась в обнаружении синтезированной и преобразованной речи на части Logical Access набора данных ASVspoof 2019. Каждая запись относилась к одному из двух классов: настоящая речь или поддельная речь, созданная средствами синтеза и преобразования голоса.

Перед передачей данных в нейронную сеть аудиозаписи преобразовывались в набор частотных признаков LFCC. Такое представление позволяет использовать информацию о распределении энергии сигнала по частотам и выделять особенности, характерные для искусственно созданной речи.

В качестве основной модели была выбрана Light CNN, адаптированная к обработке аудио. Архитектура включала последовательность сверточных слоёв, слоёв уменьшения пространственного размера и блоков Max-Feature-Map. В блоке Max-Feature-Map пары карт признаков сравниваются поэлементно, после чего сохраняется карта с более сильным откликом. После сверточной части формировалось компактное представление записи, на основании которого модель вычисляла два выходных значения для классов настоящей и поддельной речи. Архитектура была реализована на основе работ по Light CNN и системе STC для ASVspoof 2019 [4, 5].

Для обучения использовалась функция потерь Cross-Entropy, а качество оценивалось по метрике EER. Чем ниже значение EER, тем лучше модель разделяет настоящие и поддельные записи.

Обучающие данные использовались для обновления весов модели, а валидационные - для контроля качества и выбора итогового варианта.

Финальная модель обучалась в течение 20 эпох с использованием оптимизатора Adam. Начальная скорость обучения составляла $3 \cdot 10^{-4}$ и уменьшалась в два раза после десяти эпох. Размер обучающего пакета составлял

64 записи. Для предотвращения переобучения перед заключительным слоем нормализации применялся Dropout с вероятностью 0,25.

Входные признаки представляли собой 60 коэффициентов LFCC, включающих статические коэффициенты, первые и вторые производные. Каждая запись приводилась к длине 750 временных кадров: длинные записи обрезались, а короткие дополнялись нулями. Выбор LFCC и основных параметров обучения основывался на результатах сравнительного исследования методов обнаружения синтезированной речи ^[6].

До запуска полного обучения была выполнена проверка модели на одном пакете данных. Модель смогла достичь на нём значения EER, близкого к нулю, после чего обучение было продолжено на полном наборе данных.

5. ОПИСАНИЕ ВЫПОЛНЕННЫХ РАБОТ И ПОЛУЧЕННЫХ РЕЗУЛЬТАТОВ

5.1. Ход выполнения практической работы

Работа над домашним заданием началась с изучения структуры набора ASVspoof 2019 и файлов протокола. Был реализован загрузчик аудиозаписей, связывающий идентификатор файла с меткой класса. После этого была подготовлена процедура преобразования звука в признаки фиксированного размера.

Следующим этапом стала реализация модели LCNN и проверка размеров тензоров при прохождении данных через сеть. После успешной проверки прямого и обратного прохода модель была обучена на небольшом фрагменте данных, а затем - на полной обучающей выборке.

В ходе работы последовательно сравнивались несколько вариантов подготовки признаков и функции потерь. Первые эксперименты проводились со спектрограммой. Затем был исправлен способ дополнения коротких записей, что заметно улучшило результат. Наиболее существенное повышение качества было получено после перехода к признакам LFCC.


Финальное решение было оформлено как PyTorch-проект. Обучение выполнялось в Kaggle, история запуска сохранялась в Weights & Biases, а после обучения для каждой записи оценочной выборки формировался непрерывный балл принадлежности к настоящей речи.

5.2. Результаты экспериментов

Основные этапы улучшения модели представлены в таблице. В таблицу включены только наиболее показательные варианты, повлиявшие на выбор финального решения.


Вариант решения	Основное изменение	EER на eval, %
STFT-LCNN + Cross-Entropy	Первый базовый вариант	10,3323
STFT-LCNN + P2SGrad	Замена функции потерь	14,1531
STFT-LCNN + Cross-Entropy	Исправление дополнения коротких записей	8,5396
LFCC-LCNN + Cross-Entropy	Переход к LFCC и финальное обучение	5,2315

Таблица экспериментов



Изменение EER на валидационной и оценочной выборках по эпохам

Значение EER на валидационной выборке быстро уменьшилось в первые эпохи обучения и далее оставалось на низком уровне. Результат на оценочной выборке изменялся менее равномерно, что связано с наличием в ней неизвестных способов формирования поддельной речи.



Изменение значения функции потерь по эпохам

Значения функции потерь на обучающей и валидационной выборках в ходе обучения уменьшались. Более высокое значение на оценочной выборке отражает различие между известными и неизвестными типами атак.

Дополнительный эксперимент с функцией потерь P2SGrad дал EER 14,15% и не привёл к улучшению результата. Поэтому в финальной модели была сохранена Cross-Entropy. Итоговая модель была обучена в течение 20 эпох. Значение EER на валидационной выборке составило 0,2366 %, а на оценочной выборке - 5,231 %.

Разница между результатами на валидационной и оценочной выборках связана с тем, что оценочная часть содержит неизвестные модели атак. Это показало важность проверки способности модели работать с данными, отличающимися от использованных при обучении.

Исходный код и материалы финального решения размещены в репозитории GitHub^[11]. Ход обучения и значения метрик представлены в отчёте Weights & Biases^[12].

6. ЗАКЛЮЧЕНИЕ

В ходе учебной практики были выполнены поставленные задачи и достигнута основная цель. Были изучены базовые принципы глубокого обучения, основные архитектуры нейронных сетей и современные направления, включающие трансформеры, большие языковые модели, обработку аудио, мультимодальные системы и объяснимый искусственный интеллект.

Практические занятия позволили освоить создание моделей в PyTorch, организацию обучения и проверку качества полученных решений. Навыки работы с Kaggle, GitHub и Weights & Biases помогли организовать вычислительный эксперимент и сохранить его результаты.

В рамках итогового домашнего задания была разработана и обучена модель для обнаружения поддельной речи. Последовательное сравнение вариантов подготовки данных позволило улучшить результат и получить EER 5,2315 % на оценочной выборке ASVspoof 2019.

Полученные знания и навыки могут быть использованы в последующих учебных и исследовательских проектах, связанных с машинным обучением, обработкой последовательностей и мультимодальных данных.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Материалы мини-курса Deep Learning Summer 2026 [Электронный ресурс]. URL: https://github.com/Blinorot/deep-learning-research/tree/summer_2026 (дата обращения: 26.07.2026).
2. PyTorch: официальная документация [Электронный ресурс]. URL: <https://pytorch.org/docs/stable/> (дата обращения: 26.07.2026).
3. ASVspoof 2019: Automatic Speaker Verification Spoofing and Countermeasures Challenge Evaluation Plan [Электронный ресурс]. URL: https://www.asvspoof.org/asvspoof2019/asvspoof2019_evaluation_plan.pdf (дата обращения: 26.07.2026).
4. Wu X., He R., Sun Z., Tan T. A Light CNN for Deep Face Representation with Noisy Labels // IEEE Transactions on Information Forensics and Security. 2018.
5. Lavrentyeva G. et al. STC Antispoofing Systems for the ASVspoof2019 Challenge // Proceedings of Interspeech. 2019.
6. Wang X., Yamagishi J. A Comparative Study on Recent Neural Spoofing Countermeasures for Synthetic Speech Detection // Proceedings of Interspeech. 2021.
7. ASVspoof 2019 Dataset [Электронный ресурс]. URL: <https://datashare.ed.ac.uk/handle/10283/3336> (дата обращения: 26.07.2026).
8. Kaggle: платформа для машинного обучения [Электронный ресурс]. URL: <https://www.kaggle.com/> (дата обращения: 26.07.2026).
9. Weights & Biases: официальная документация [Электронный ресурс]. URL: <https://docs.wandb.ai/> (дата обращения: 26.07.2026).
10. Python: официальная документация [Электронный ресурс]. URL: <https://docs.python.org/3/> (дата обращения: 26.07.2026).
11. Путинцева В. А. Репозиторий проекта «LFCC-LCNN для Voice Anti-spoofing» [Электронный ресурс]. URL: https://github.com/vputt/hw_dl (дата обращения: 26.07.2026).

12. Путинцева В. А. Отчёт об экспериментах проекта «LFCC-LCNN для Voice Anti-spoofing» // Weights & Biases [Электронный ресурс]. URL: <https://api.wandb.ai/links/putinsevav-hse-university/f20qdl6j> (дата обращения: 26.07.2026).

ПРИЛОЖЕНИЕ

Рабочий план-график прохождения практики с отметками о выполнении:

№ п/п	Сроки проведения	Планируемые работы	Отметка о выполнении
1	01.07.2026 – 06.07.2026	Изучение основных концепций глубинного обучения	+
2	07.07.2026 – 09.07.2026	Знакомство с продвинутыми разделами	+
3	10.07.2026 – 14.07.2026	Решение домашнего задания	+